

Práctica 2 –

Infraestructuras de Big Data (día 1)

Diseño de una infraestructura de datos para el análisis ambiental en el Ayuntamiento de Madrid

Grupos de hasta 4 estudiantes

1. Contexto y Objetivo

El Ayuntamiento de Madrid ha puesto en marcha una iniciativa orientada a reforzar sus capacidades de análisis de datos ambientales, con el objetivo de comprender mejor el comportamiento del entorno urbano y facilitar la toma de decisiones basada en datos.

En este contexto, se plantea el diseño de una infraestructura que permita recopilar información procedente de distintas fuentes externas, procesarla de forma periódica y almacenarla de modo que pueda ser utilizada posteriormente en procesos analíticos.

Los ámbitos de interés del proyecto abarcan diferentes dimensiones del entorno ambiental, entre las que se incluyen las condiciones meteorológicas, la calidad del aire, los niveles de radiación, la elevación del terreno y las previsiones climáticas.

Para dar soporte a este sistema, el Ayuntamiento dispone de acceso a servicios de datos abiertos ofrecidos por la plataforma Open-Meteo (<https://open-meteo.com>), que permiten recuperar información basada en coordenadas geográficas y series temporales. Estos servicios constituyen una de las principales fuentes de datos sobre las que se construirá la solución propuesta. Adicionalmente, el Ayuntamiento pone a disposición del público distintos conjuntos de datos a través de su portal de datos abiertos (<https://datos.madrid.es/>).

La infraestructura deberá ser capaz de trabajar con este tipo de fuentes heterogéneas, teniendo en cuenta sus diferentes características y formas de acceso.

2. Requisitos del sistema

La infraestructura a desarrollar deberá ser capaz de:

- recuperar datos desde, **al menos, dos fuentes distintas** de datos.
- **almacenar** la información sin pérdida de datos. El sistema deberá implementar un repositorio que permita conservar los datos originales, almacenar versiones transformadas, y preparar los datos para su consumo.
- generar una versión preparada y optimizada de datos para su **procesamiento analítico** desde entornos de programación.
- soportar la ejecución de **flujos de trabajo** reutilizables que automaticen la ingesta, transformación y almacenamiento de datos.
- ejecutar procesos de ingesta de forma **periódica**. El sistema deberá recuperar los datos correspondientes al día anterior al momento de ejecución

3. Restricciones y resultado esperado

La solución deberá implementarse **exclusivamente utilizando tecnologías y técnicas vistas en clase**.

Cualquier solución que utilice herramientas o enfoques no cubiertos en la asignatura será considerada **incorrecta**.

La infraestructura deberá desplegarse utilizando **contenedores** y deberá garantizar:

- **persistencia** de los datos
- **comunicación** entre componentes
- **aislamiento** de servicios

Durante esta primera fase, cada grupo deberá crear un **repositorio privado en GitHub** que contendrá todos los elementos necesarios para el despliegue de la infraestructura:

- **archivos de configuración** necesarios para desplegar la infraestructura
- cualquier **código** desarrollado durante la práctica

El repositorio deberá incluir un fichero **README.md** en el que se describa:

- la **arquitectura** implementada
- los **componentes** utilizados
- los pasos necesarios para la **configuración y puesta en marcha del sistema**

Dado que en esta fase pueden existir pasos manuales, estos deberán estar claramente documentados.

4. Entrega Final

Al finalizar la segunda sesión, cada grupo deberá subir a **Moodle**:

- un **archivo ZIP** que contenga el repositorio completo del proyecto
- un archivo o texto indicando la **URL del repositorio en GitHub**

La entrega debe corresponder exactamente con la **release final del repositorio**.

5. Evaluación de la práctica

La entrega del sistema es **obligatoria** para poder acceder al cuestionario individual. La calificación final se basará en un **cuestionario individual** sobre la práctica. La entrega no determina la nota final por sí misma.